

Seu Nome Completo

**Análise das Propriedades Estatísticas de Dollar
Bars vs Time Bars e seus Impactos em Modelos
GARCH**

Sua Cidade

2026

Seu Nome Completo

Análise das Propriedades Estatísticas de Dollar Bars vs Time Bars e seus Impactos em Modelos GARCH

Trabalho de Conclusão de Curso apresentado
ao curso de Estatística como requisito parcial
para obtenção do título de Bacharel.

Sua Universidade – Curso de Estatística

Orientador: Nome do seu Orientador

Sua Cidade

2026

LISTA DE FIGURAS

Figura 1 – Ilustração para a estimação do TSRV.	17
Figura 2 – Histograma com curva normal e QQ-Plot — Dollar Bars (5 min). . . .	29
Figura 3 – Histograma com curva normal e QQ-Plot — Time Bars (5 min). . . .	29
Figura 4 – ACF e PACF dos retornos ao quadrado — Dollar Bars (5 min). . . .	29
Figura 5 – ACF e PACF dos retornos ao quadrado — Time Bars (5 min). . . .	30
Figura 6 – AIC médio por fold CPCV — Dollar Bars vs. Time Bars.	33

LISTA DE TABELAS

Tabela 1	– Estatísticas descritivas dos retornos logarítmicos.	27
Tabela 2	– Testes de normalidade, estacionariedade e heteroscedasticidade sobre os retornos logarítmicos.	28
Tabela 3	– Divisão treino-teste por tipo de barra.	30
Tabela 4	– Resultados da seleção de parâmetros via CPCV.	32
Tabela 5	– Critérios de informação do modelo final estimado sobre o conjunto de treino completo.	33
Tabela 6	– Métricas de avaliação das previsões de variância vs. RV <i>benchmark</i> . . .	35
Tabela 7	– Intervalos de confiança bootstrap (95%) para as métricas de avaliação.	36

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
GARCH	Generalized Autoregressive Conditional Heteroskedasticity
CPCV	Combinatorial Purged Cross-Validation
MCMC	Markov Chain Monte Carlo
MLE	Maximum Likelihood Estimation
BIC	Bayesian Information Criterion
AIC	Akaike Information Criterion
LSTM	Long Short-Term Memory

SUMÁRIO

1	INTRODUÇÃO	8
1.1	Objetivos	9
1.1.1	Objetivo Geral	9
1.1.2	Objetivos Específicos	9
1.2	Justificativa	9
2	REFERENCIAL TEÓRICO	11
2.1	Construção de Time Bars e Dollar Bars	11
2.1.1	Time Bars	11
2.1.2	Dollar Bars	12
2.2	Modelos Econométricos ARIMA-GARCH	13
2.2.1	Modelo ARIMA	13
2.2.2	Modelo GARCH	14
2.2.3	Estimação Conjunta ARIMA-GARCH	14
2.3	Volatilidade Realizada e o Estimador Two-Scale	15
2.3.1	Volatilidade Realizada	16
2.3.2	Estimador Two-Scale Realized Volatility (TSRV)	16
2.3.2.1	Formulação	16
2.3.2.2	Propriedades	17
2.4	Validação Cruzada Combinatória Purgada (CPCV)	18
2.4.1	Formulação	18
2.4.2	Número de Caminhos de Backtest	18
2.5	Métricas de Avaliação de Previsões de Volatilidade	19
2.5.1	Funções de Perda	19
2.5.1.1	Erro Quadrático Médio (MSE)	19
2.5.1.2	Erro Absoluto Médio (MAE)	19
2.5.1.3	Função de Perda QLIKE	20
2.5.2	Regressão de Mincer–Zarnowitz	20
2.5.3	Teste de Diebold–Mariano	20
2.5.4	Intervalos de Confiança Bootstrap	21
3	METODOLOGIA	22
3.1	Dados e Período Amostral	22
3.1.1	Coleta e Pré-processamento dos Dados de Alta Frequência	22
3.1.1.1	Arquitetura de Processamento por <i>Streaming</i> via <i>Row Groups</i>	23

3.1.1.2	Extração do Preço Eficiente por Filtro IIR	23
3.1.1.3	Aceleração por Compilação JIT via Numba	24
3.1.2	Estimação da Volatilidade Realizada	24
3.1.2.1	Two-Scale Realized Volatility (TSRV)	24
3.1.2.2	Amostragem em Tempo Calendário	25
3.1.2.3	Processamento Diário Eficiente (TickDataProcessor)	26
3.1.2.4	Benchmark de Consenso Multi-Frequência	26
3.2	Análise Exploratória das Séries	26
3.2.1	Estatísticas Descritivas	26
3.2.2	Testes de Normalidade, Estacionariedade e Heteroscedasticidade	27
3.3	Construção dos Retornos Logarítmicos	30
3.4	Divisão Treino-Teste	30
3.5	Seleção de Parâmetros via CPCV	31
3.5.1	Configuração do CPCV	31
3.5.2	Grid de Busca	31
3.5.3	Resultados da Seleção	32
3.6	Estimação do Modelo Final	33
3.7	Agregação para Nível Diário	33
3.8	Métricas de Avaliação e Testes Estatísticos	34
3.8.1	Funções de Perda e Regressão Mincer-Zarnowitz	34
3.8.2	Teste de Diebold-Mariano	35
3.8.3	Intervalos de Confiança Bootstrap	35
4	RESULTADOS E DISCUSSÃO	37
4.1	Propriedades Estatísticas Comparativas das Séries	37
4.2	Seleção de Modelos via CPCV	38
4.3	Desempenho Preditivo Fora da Amostra	39
4.3.1	Métricas Pontuais	39
4.3.2	Regressão de Mincer-Zarnowitz	40
4.3.3	Teste de Diebold-Mariano	40
4.3.4	Intervalos de Confiança Bootstrap	41
4.4	Limitações e Ressalvas	42
4.4.0.0.1	Ativo único.	42
4.4.0.0.2	Período amostral.	42
4.4.0.0.3	Calibração do limiar $\bar{D}$	42
4.4.0.0.4	Distribuição dos erros.	42
4.5	Síntese do Capítulo	43
5	CONCLUSÃO	44
5.1	Retomada dos Objetivos Específicos	44

5.2	Resposta à Pergunta Central	45
5.3	Contribuições do Trabalho	45
5.4	Limitações	46
5.5	Agenda de Pesquisa Futura	46
	REFERÊNCIAS BIBLIOGRÁFICAS	48
	APÊNDICES	49

1 INTRODUÇÃO

A modelagem da volatilidade de ativos financeiros constitui um dos pilares da econometria financeira moderna, com aplicações diretas na gestão de risco, na precificação de derivativos e na alocação de portfólios (??). Desde a introdução dos modelos ARCH por ??) e sua generalização GARCH por ??), a literatura tem avançado significativamente na compreensão da dinâmica temporal da variância condicional de retornos financeiros. Entretanto, a qualidade dos modelos estimados depende fundamentalmente da forma com que os dados brutos de mercado são pré-processados e agregados — uma etapa frequentemente negligenciada na prática.

A forma mais comum de agregação de dados financeiros de alta frequência é a construção de barras temporais (*time bars*), nas quais as observações são agrupadas em intervalos fixos de tempo. Contudo, ??) demonstrou que essa abordagem introduz distorções estatísticas relevantes: sobre-amostragem em períodos de baixa atividade, sub-amostragem em períodos de alta atividade, e retornos com propriedades que se afastam das premissas de modelos econométricos tradicionais. Como alternativa, o autor propôs as *dollar bars*, barras baseadas no volume financeiro transacionado, que produzem séries com propriedades estatísticas mais favoráveis à modelagem.

A questão que surge naturalmente é: *em que medida a escolha do método de amostragem — time bars versus dollar bars — afeta a qualidade das estimativas de volatilidade obtidas por modelos ARMA-GARCH?* Esta pergunta tem relevância prática direta, pois a estimativa da variância condicional é insumo para decisões de investimento, *hedging* e controle de risco.

Adicionalmente, a avaliação de modelos em séries temporais financeiras requer cuidados metodológicos específicos. A dependência temporal entre observações invalida métodos tradicionais de validação cruzada, e a prática de selecionar o “melhor modelo” com base em métricas *in-sample* pode conduzir a sobreajuste (*overfitting*). O arcabouço de Validação Cruzada Combinatória Purgada (CPCV), proposto por ??), endereça essas limitações ao gerar múltiplos caminhos de *backtest* e permitir a estimação das estatísticas em séries temporais com maior rigor.

1.1 OBJETIVOS

1.1.1 OBJETIVO GERAL

Analisar o impacto da escolha do método de amostragem de dados financeiros — *time bars* versus *dollar bars* — sobre as propriedades estatísticas das séries resultantes e sobre a qualidade preditiva de modelos ARMA-GARCH para a variância condicional de retornos, utilizando o estimador Two-Scale Realized Volatility (TSRV) para a variância realizada, como referência e o arcabouço CPCV para avaliação comparativa robusta.

1.1.2 OBJETIVOS ESPECÍFICOS

1. Construir séries de retornos a partir de *time bars* e *dollar bars* para um ativo financeiro selecionado, comparando suas propriedades estatísticas descritivas;
2. Estimar a variância realizada por meio do estimador TSRV;
3. Ajustar modelos ARMA-GARCH conjuntos sobre ambos os tipos de barra, selecionando as ordens ótimas por critérios de informação;
4. Avaliar e comparar o desempenho preditivo dos modelos utilizando métricas de erro de previsão de volatilidade (MSE, MAE, QLIKE, MZ).
5. Comparar o desempenho preditivo dos modelos com o estimador TSRV.

1.2 JUSTIFICATIVA

A escolha do método de amostragem de dados financeiros é uma decisão metodológica de primeira ordem que afeta toda a cadeia subsequente de modelagem e inferência. Apesar de amplamente discutida na literatura de aprendizado de máquina financeiro (??), a interação entre métodos de amostragem alternativos e modelos econométricos clássicos de volatilidade — particularmente a família GARCH — permanece pouco explorada na literatura acadêmica brasileira.

Este trabalho justifica-se pela necessidade de:

1. **Preencher uma lacuna metodológica:** a maioria dos estudos que empregam modelos GARCH utiliza *time bars* sem questionar as implicações dessa escolha. Uma análise comparativa rigorosa contribui para a compreensão de como o método de amostragem afeta as estimativas de volatilidade;
2. **Adotar uma avaliação robusta:** o uso do CPCV representa uma abordagem metodologicamente superior ao *walk-forward* simples, comumente empregado em trabalhos aplicados;

3. **Integrar estimadores eficientes:** o estimador TSRV é uma alternativa de estimação em cima de tick data para a estimação de variância realizada mais precisa do que o retorno quadrático simples, permitindo uma avaliação mais fidedigna dos modelos.

2 REFERENCIAL TEÓRICO

Este capítulo apresenta os fundamentos teóricos que sustentam a metodologia adotada neste trabalho. Na [seção 2.1](#), discute-se a construção de barras de amostragem alternativas — *time bars* e *dollar bars* — e suas implicações estatísticas. A [seção 2.2](#) introduz os modelos econométricos ARIMA-GARCH para a modelagem conjunta da média e da variância condicional de séries financeiras. Na [seção 2.3](#), apresenta-se o conceito de volatilidade realizada e o estimador *Two-Scale Realized Volatility* (TSRV), utilizado como referência (*benchmark*) para a avaliação das previsões de variância. A ?? descreve o arcabouço de Validação Cruzada Combinatória Purgada (CPCV) utilizado para avaliar e comparar o desempenho preditivo dos modelos sob diferentes regimes de amostragem. Por fim, a ?? apresenta as métricas de avaliação empregadas — funções de perda, regressão de Mincer–Zarnowitz, teste de Diebold–Mariano e intervalos de confiança *bootstrap*.

2.1 CONSTRUÇÃO DE TIME BARS E DOLLAR BARS

A forma com que dados financeiros de alta frequência são agregados em barras de preço exerce influência direta sobre as propriedades estatísticas da série resultante e, conseqüentemente, sobre a qualidade dos modelos nela estimados (??). Esta seção apresenta os dois métodos de amostragem empregados neste trabalho.

2.1.1 TIME BARS

Time bars constituem o método mais tradicional de amostragem de dados financeiros, no qual as observações são agrupadas em intervalos fixos de tempo — por exemplo, barras de 1 minuto, 5 minutos, 1 hora ou 1 dia. Para cada intervalo $[t, t + \Delta t)$, registram-se os preços de abertura (O), máximo (H), mínimo (L) e fechamento (C), bem como o volume total negociado (V) (??).

A construção é direta: dada uma sequência de *ticks* $\{(p_i, v_i, \tau_i)\}_{i=1}^M$, em que p_i é o preço, v_i é o volume e τ_i é o instante da i -ésima transação, define-se a j -ésima *time bar* como o conjunto de *ticks* cujos instantes satisfazem $\tau_i \in [t_j, t_j + \Delta t)$, de modo que:

$$\text{Bar}_j^{\text{time}} = (O_j, H_j, L_j, C_j, V_j), \quad (2.1)$$

onde $O_j = p_{\min\{i:\tau_i \geq t_j\}}$, $H_j = \max\{p_i : \tau_i \in [t_j, t_j + \Delta t)\}$, $L_j = \min\{p_i : \tau_i \in [t_j, t_j + \Delta t)\}$, $C_j = p_{\max\{i:\tau_i < t_j + \Delta t\}}$ e $V_j = \sum_{\tau_i \in [t_j, t_j + \Delta t)} v_i$.

Apesar de amplamente utilizadas, as *time bars* apresentam limitações bem documentadas (??):

- i) **Sobre-amostragem em períodos de baixa atividade:** durante períodos de baixo volume de negociação, como horários noturnos ou feriados parciais, as barras contêm poucas transações, resultando em medidas de preço ruidosas e pouco representativas;
- ii) **Sub-amostragem em períodos de alta atividade:** durante eventos de mercado com elevada atividade — anúncios de resultados corporativos, decisões de política monetária, choques exógenos — a informação é comprimida em poucas barras, ocasionando perda de resolução;
- iii) **Propriedades estatísticas indesejáveis:** os retornos derivados de *time bars* frequentemente exibem autocorrelação serial, heterocedasticidade e afastamento pronunciado da normalidade (caudas pesadas), violando premissas comuns de modelos estatísticos e de aprendizado de máquina.

2.1.2 DOLLAR BARS

Dollar bars são um tipo de barra baseada em atividade de mercado, proposta por ??), na qual uma nova barra é formada sempre que o volume financeiro acumulado — produto entre preço e quantidade — atinge um limiar pré-definido $\bar{D}$. Formalmente, dado o fluxo de *ticks* $\{(p_i, v_i, \tau_i)\}_{i=1}^M$, o índice de encerramento da j -ésima *dollar bar* é definido como:

$$T_j = \inf \left\{ t > T_{j-1} : \sum_{i=T_{j-1}+1}^t p_i v_i \geq \bar{D} \right\}, \quad T_0 = 0, \quad (2.2)$$

e a barra resultante é:

$$\text{Bar}_j^{\text{dollar}} = (O_j, H_j, L_j, C_j, V_j), \quad (2.3)$$

cujos campos OHLCV são computados de maneira análoga à [Equação 2.1](#), porém sobre o intervalo de *ticks* $\{T_{j-1} + 1, \dots, T_j\}$.

A escolha do limiar $\bar{D}$ é usualmente feita de modo que o número médio de barras por dia seja comparável ao que seria obtido com *time bars* em uma frequência desejada, garantindo consistência na quantidade de observações (?).

As *dollar bars* possuem propriedades estatísticas superiores em relação às *time bars* (?):

- i) **Robustez a variações de preço e volume:** ao amostrar com base no valor financeiro transacionado, as *dollar bars* normalizam a atividade de mercado, tornando-se menos sensíveis a mudanças no nível de preço do ativo ao longo do tempo;
- ii) **Homogeneidade informacional:** cada barra captura, aproximadamente, a mesma quantidade de “informação de mercado”, no sentido de que o volume financeiro é um *proxy* da intensidade de atividade dos participantes;

- iii) **Retornos mais próximos de IID:** evidências empíricas demonstram que os retornos derivados de *dollar bars* são mais próximos de uma distribuição gaussiana e independente do que os obtidos por *time bars*, facilitando a aplicação de modelos estatísticos tradicionais e de aprendizado de máquina.

2.2 MODELOS ECONOMETRICOS ARIMA-GARCH

A modelagem conjunta da média e da variância condicional de séries temporais financeiras constitui uma abordagem central em econometria financeira. A combinação de modelos ARIMA para a equação da média com modelos GARCH para a equação da variância permite capturar simultaneamente a estrutura de dependência linear nos retornos e o fenômeno de agrupamento de volatilidade (*volatility clustering*) (????).

2.2.1 MODELO ARIMA

O modelo Autorregressivo Integrado de Médias Móveis — ARIMA(p, d, q) — foi proposto por ??) e constitui uma classe geral de modelos lineares para séries temporais estacionárias ou tornadas estacionárias por meio de diferenciação.

Seja $\{Y_t\}$ uma série temporal. A operação de diferenciação de ordem d é definida por $W_t = (1 - B)^d Y_t$, em que B é o operador de retardo ($BY_t = Y_{t-1}$). O modelo ARIMA(p, d, q) assume que a série diferenciada $\{W_t\}$ segue um processo ARMA(p, q):

$$\phi(B) (1 - B)^d Y_t = \mu + \theta(B) \varepsilon_t, \quad (2.4)$$

em que:

- $\phi(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$ é o polinômio autorregressivo de ordem p ;
- $\theta(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q$ é o polinômio de médias móveis de ordem q ;
- μ é uma constante (intercepto);
- $\{\varepsilon_t\}$ é um processo ruído branco com $E[\varepsilon_t] = 0$ e $\text{Var}[\varepsilon_t] = \sigma^2$.

A estacionariedade da componente autorregressiva requer que todas as raízes de $\phi(z) = 0$ estejam fora do círculo unitário, e a invertibilidade da componente de médias móveis exige que todas as raízes de $\theta(z) = 0$ também estejam fora do círculo unitário (??).

A identificação das ordens (p, d, q) pode ser realizada pela análise das funções de autocorrelação (FAC) e autocorrelação parcial (FACP) da série diferenciada, conforme a metodologia de Box–Jenkins, ou por critérios de informação como o AIC (*Akaike*

Information Criterion) e BIC (*Bayesian Information Criterion*), definidos respectivamente por (2.5):

$$\text{AIC} = -2 \ln \hat{\mathcal{L}} + 2k, \quad (2.5)$$

$$\text{BIC} = -2 \ln \hat{\mathcal{L}} + k \ln n, \quad (2.6)$$

onde $\hat{\mathcal{L}}$ é o valor maximizado da função de verossimilhança, k é o número de parâmetros estimados e n é o tamanho amostral.

2.2.2 MODELO GARCH

O modelo de Heterocedasticidade Condicional Autorregressiva Generalizada — GARCH(r, s) — foi proposto por Bollerslev (1986) como generalização do modelo ARCH de Engle (1982). O modelo captura o fenômeno empírico de que a volatilidade de retornos financeiros tende a se agrupar em períodos: grandes variações são seguidas por grandes variações, e pequenas variações por pequenas variações.

Considere que os resíduos da equação da média podem ser escritos como $\varepsilon_t = \sigma_t z_t$, em que $z_t \sim \text{i.i.d.}(0, 1)$. O modelo GARCH(r, s) especifica a variância condicional como:

$$\sigma_t^2 = \omega + \sum_{i=1}^r \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^s \beta_j \sigma_{t-j}^2, \quad (2.7)$$

sujeito às restrições de não-negatividade e estacionariedade: $\omega > 0$, $\alpha_i \geq 0$, $\beta_j \geq 0$ e $\sum_{i=1}^r \alpha_i + \sum_{j=1}^s \beta_j < 1$.

Na especificação GARCH(1, 1) — amplamente empregada na prática (Bollerslev, 1986) — a equação simplifica-se para:

$$\sigma_t^2 = \omega + \alpha_1 \varepsilon_{t-1}^2 + \beta_1 \sigma_{t-1}^2, \quad (2.8)$$

e a variância incondicional (de longo prazo) é dada por:

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha_1 - \beta_1}. \quad (2.9)$$

2.2.3 ESTIMAÇÃO CONJUNTA ARIMA-GARCH

Na prática, a equação da média e a equação da variância são estimadas conjuntamente via Máxima Verossimilhança (MV) ou Quase-Máxima Verossimilhança (QMV), o que garante a eficiência assintótica dos estimadores mesmo quando a distribuição dos erros padronizados z_t não é exatamente gaussiana (Engle, 1982).

O modelo ARIMA(p, d, q)-GARCH(r, s) completo é dado pelo sistema:

$$\begin{cases} \phi(B)(1-B)^d Y_t = \mu + \theta(B) \varepsilon_t & \text{(equação da média),} \\ \varepsilon_t = \sigma_t z_t, \quad z_t \sim D(0, 1) & \text{(inovações padronizadas),} \\ \sigma_t^2 = \omega + \sum_{i=1}^r \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^s \beta_j \sigma_{t-j}^2 & \text{(equação da variância),} \end{cases} \quad (2.10)$$

em que $D(0, 1)$ denota uma distribuição com média zero e variância unitária.

Assumindo normalidade condicional, a função de log-verossimilhança é:

$$\ell(\boldsymbol{\vartheta}) = -\frac{T}{2} \ln(2\pi) - \frac{1}{2} \sum_{t=1}^T \left[\ln \sigma_t^2 + \frac{\varepsilon_t^2}{\sigma_t^2} \right], \quad (2.11)$$

onde $\boldsymbol{\vartheta} = (\mu, \phi_1, \dots, \phi_p, \theta_1, \dots, \theta_q, \omega, \alpha_1, \dots, \alpha_r, \beta_1, \dots, \beta_s)^\top$ é o vetor de parâmetros e T é o número de observações.

O procedimento de estimação segue, em geral, as seguintes etapas (??):

1. **Verificação de estacionariedade:** aplica-se o teste Aumentado de Dickey–Fuller (ADF) à série original. Se a hipótese nula de raiz unitária não for rejeitada, diferencia-se a série ($d \geq 1$);
2. **Identificação da equação da média:** analisam-se a FAC e FACP da série estacionária e/ou utilizam-se critérios de informação para selecionar as ordens (p, q) ;
3. **Teste de efeitos ARCH:** aplica-se o teste de ??) ou o teste de Ljung–Box sobre os resíduos quadráticos para verificar a presença de heterocedasticidade condicional;
4. **Estimação conjunta:** ajusta-se o modelo completo ARIMA(p, d, q)-GARCH(r, s) via MV, permitindo que os parâmetros de ambas as equações sejam otimizados simultaneamente;
5. **Diagnóstico:** verificam-se os resíduos padronizados $\hat{z}_t = \hat{\varepsilon}_t / \hat{\sigma}_t$ quanto à ausência de autocorrelação, ausência de efeitos ARCH remanescentes e adequação distribucional.

2.3 VOLATILIDADE REALIZADA E O ESTIMADOR TWO-SCALE

A avaliação do desempenho preditivo de modelos de variância condicional requer uma medida de referência (*benchmark*) que se aproxime da verdadeira volatilidade latente do ativo. A **Volatilidade Realizada** (*Realized Volatility* — RV), construída a partir de retornos intradiários de alta frequência, constitui o estimador mais amplamente utilizado para esse propósito na literatura de microestrutura de mercado (??).

2.3.1 VOLATILIDADE REALIZADA

Seja $p(t)$ o logaritmo do preço de um ativo no instante t . Dividindo o dia de negociação em M subintervalos igualmente espaçados, define-se o i -ésimo retorno intradiário como $r_i = p(t_i) - p(t_{i-1})$, $i = 1, \dots, M$. A volatilidade realizada é definida como a soma dos retornos quadráticos:

$$RV_M = \sum_{i=1}^M r_i^2. \quad (2.12)$$

Sob condições de regularidade (ausência de ruído de microestrutura e processo de preço contínuo), tem-se que RV_M converge em probabilidade para a variação quadrática integrada (*integrated variance*) à medida que a frequência de amostragem aumenta, ou seja, $RV_M \xrightarrow{p} \int_0^1 \sigma^2(t) dt$ quando $M \rightarrow \infty$ (??).

Entretanto, na prática, os preços de ativos negociados em mercados eletrônicos são contaminados por **ruído de microestrutura** — efeito decorrente de *bid-ask spreads*, discretização de preços e fricções de mercado. Esse ruído torna a estimativa da RV inconsistente em frequências muito altas: à medida que se aumenta M , o viés introduzido pelo ruído domina o sinal de volatilidade, e a RV diverge em vez de convergir (??).

2.3.2 ESTIMADOR TWO-SCALE REALIZED VOLATILITY (TSRV)

Para contornar o problema de viés induzido pelo ruído de microestrutura, ??) propuseram o estimador **Two-Scale Realized Volatility** (TSRV), que combina estimativas da volatilidade realizada em duas escalas de frequência distintas — uma rápida (alta frequência) e uma lenta (baixa frequência) — de modo a eliminar assintoticamente o viés do ruído.

2.3.2.1 FORMULAÇÃO

Considere uma partição do dia de negociação em M subintervalos à frequência mais alta disponível (escala rápida). Para a escala lenta, define-se uma subamostragem de tamanho K , com $K \ll M$, formando K grades (*grids*) deslocadas. Para cada grade $g = 1, \dots, K$, calcula-se a volatilidade realizada correspondente $RV^{(g)}$ sobre a subamostra g . A volatilidade realizada na escala lenta (*slow scale*) é então a média:

$$\overline{RV}_K = \frac{1}{K} \sum_{g=1}^K RV^{(g)}. \quad (2.13)$$

O estimador TSRV é definido como:

$$TSRV = \overline{RV}_K - \frac{\bar{n}}{M} RV_M, \quad (2.14)$$

onde $\bar{n} = (M - K + 1)/K$ é o número médio de observações por grade na escala lenta. O termo $\frac{\bar{n}}{M} RV_M$ corrige o viés assintótico, subtraindo a contribuição estimada do ruído de microestrutura.

Para efeito de ilustração, é feito por meio do seguinte esquema:




Figura 1 – Ilustração para a estimação do TSRV.

2.3.2.2 PROPRIEDADES

O estimador TSRV possui as seguintes propriedades (??):

- i) **Consistência**: $TSRV \xrightarrow{p} \int_0^1 \sigma^2(t) dt$ quando $M \rightarrow \infty$, desde que $K = O(M^{2/3})$;
- ii) **Taxa de convergência ótima**: sob a escolha $K = c \cdot M^{2/3}$ para uma constante $c > 0$ apropriada, o TSRV atinge a taxa de convergência $O_p(M^{-1/6})$, que é a minimax-ótima para estimação de volatilidade na presença de ruído;
- iii) **Robustez ao ruído**: ao contrário da RV simples, o TSRV não diverge em frequências muito altas, podendo utilizar toda a informação intradiária disponível.

Neste trabalho, a volatilidade realizada diária empregada como *benchmark* para avaliação dos modelos ARIMA-GARCH é calculada pelo estimador TSRV a partir de dados *tick-by-tick* do ativo, agregados em diferentes frequências de amostragem (30 segundos, 1 minuto e 2 minutos). A estimativa final (denominada *RV consenso*) é obtida pela média das três frequências, conferindo maior robustez ao *benchmark*.

2.4 VALIDAÇÃO CRUZADA COMBINATÓRIA PURGADA (CPCV)

A avaliação de desempenho de modelos em séries temporais financeiras enfrenta desafios específicos que invalidam a aplicação direta de técnicas padrão de validação cruzada. A dependência temporal entre observações implica que a separação aleatória

entre conjuntos de treino e teste pode introduzir vazamento de informação (*information leakage*), conduzindo a estimativas otimistas e não confiáveis do erro de generalização (??).

A Validação Cruzada Combinatória Purgada (*Combinatorial Purged Cross-Validation* — CPCV), proposta por ??), endereça essas limitações por meio de três mecanismos: (i) geração combinatória de múltiplas partições treino-teste, (ii) purgação de observações sobrepostas e (iii) embargo temporal.

2.4.1 FORMULAÇÃO

Considere um conjunto de dados com T observações ordenadas cronologicamente. O procedimento CPCV opera da seguinte forma:

1. **Particionamento:** o conjunto de dados é dividido em N grupos sequenciais e não-sobrepostos $G_1, G_2, \dots, G_N$, cada um contendo aproximadamente T/N observações;
2. **Geração combinatória:** selecionam-se todas as combinações possíveis de k grupos para compor o conjunto de teste, resultando em $\binom{N}{k}$ partições distintas de treino-teste. Os demais $N - k$ grupos formam o respectivo conjunto de treino;
3. **Purgação (*purging*):** para cada partição, removem-se do conjunto de treino as observações cujos rótulos (variáveis-resposta) apresentem sobreposição temporal com os rótulos do conjunto de teste, eliminando vazamento direto de informação;
4. **Embargo:** adicionalmente, remove-se do conjunto de treino um número de observações imediatamente subsequentes ao final de cada bloco de teste, denominado período de embargo (h). Essa exclusão mitiga o vazamento indireto decorrente da correlação serial entre observações próximas.

2.4.2 NÚMERO DE CAMINHOS DE BACKTEST

Uma propriedade fundamental do CPCV é a geração de múltiplos caminhos de *backtest* que cobrem toda a extensão temporal do conjunto de dados. O número de caminhos distintos é dado por (??):

$$\varphi(N, k) = \binom{N}{k} \cdot \frac{k}{N} = \binom{N-1}{k-1}. \quad (2.15)$$

Cada caminho corresponde a uma sequência cronológica completa de previsões fora-da-amostra, permitindo a construção de uma distribuição empírica de métricas de desempenho em vez de uma única estimativa pontual.

2.5 MÉTRICAS DE AVALIAÇÃO DE PREVISÕES DE VOLATILIDADE

A avaliação da qualidade de previsões de variância condicional requer métricas que sejam robustas ao uso de *proxies* ruidosos da volatilidade verdadeira (latente). ??) demonstrou que apenas determinadas funções de perda preservam o ordenamento correto de modelos quando a variância realizada é utilizada como *proxy* imperfeito da volatilidade verdadeira. As métricas empregadas neste trabalho pertencem a essa classe robusta e são complementadas pela regressão de Mincer–Zarnowitz, pelo teste de Diebold–Mariano e por intervalos de confiança *bootstrap*.

Em todas as expressões a seguir, sejam $\hat{\sigma}_t^2$ a variância condicional prevista pelo modelo e ξ_t a volatilidade realizada (TSRV) no dia t , para $t = 1, \dots, T$.

2.5.1 FUNÇÕES DE PERDA

2.5.1.1 ERRO QUADRÁTICO MÉDIO (MSE)

O Erro Quadrático Médio penaliza proporcionalmente ao quadrado do desvio entre previsão e *benchmark*:

$$\text{MSE} = \frac{1}{T} \sum_{t=1}^T (\hat{\sigma}_t^2 - \xi_t)^2. \quad (2.16)$$

Por ser quadrática, a MSE atribui peso maior a erros de grande magnitude, tornando-se sensível a episódios de volatilidade extrema. Pertence à classe de funções de perda robustas de ??), garantindo que o *ranking* de modelos é consistente mesmo quando ξ_t é um *proxy* ruidoso.

2.5.1.2 ERRO ABSOLUTO MÉDIO (MAE)

O Erro Absoluto Médio oferece uma medida mais robusta a *outliers* do que a MSE, pois penaliza linearmente os desvios:

$$\text{MAE} = \frac{1}{T} \sum_{t=1}^T |\hat{\sigma}_t^2 - \xi_t|. \quad (2.17)$$

2.5.1.3 FUNÇÃO DE PERDA QLIKE

A função de perda *quasi-likelihood* (QLIKE), proposta por ??), pertence à classe de funções de perda robustas e penaliza assimetricamente sub e sobre-estimação:

$$\text{QLIKE} = \frac{1}{T} \sum_{t=1}^T \left(\ln \hat{\sigma}_t^2 + \frac{\xi_t}{\hat{\sigma}_t^2} \right). \quad (2.18)$$

A QLIKE é especialmente relevante porque seu *ranking* de modelos é preservado independentemente da *proxy* utilizada, bastando que esta seja proporcional à verdadeira variância. Valores mais negativos indicam melhor aderência.

2.5.2 REGRESSÃO DE MINCER–ZARNOWITZ

A regressão de Mincer–Zarnowitz (??) constitui um teste clássico de avaliação de previsões. Estima-se por Mínimos Quadrados Ordinários (MQO) a regressão:

$$\xi_t = \alpha + \beta \hat{\sigma}_t^2 + \varepsilon_t, \quad (2.19)$$

onde ε_t é o termo de erro. Sob a hipótese nula de que a previsão é **ótima e não-viesada**, espera-se:

$$H_0 : \alpha = 0 \text{ e } \beta = 1. \quad (2.20)$$

O coeficiente α captura o viés sistemático da previsão: $\alpha \neq 0$ indica que, em média, a previsão sobre ou subestima a volatilidade realizada. O coeficiente β mede a sensibilidade da realização às previsões: $\beta < 1$ sugere atenuação (a previsão sobreestima a amplitude das variações de volatilidade), enquanto $\beta > 1$ indica amplificação.

O **coeficiente de determinação** R^2 da regressão quantifica a proporção da variação da volatilidade realizada explicada pelas previsões do modelo, sendo interpretado como medida de poder preditivo. Um R^2 elevado indica que o modelo captura satisfatoriamente a dinâmica temporal da volatilidade.

2.5.3 TESTE DE DIEBOLD–MARIANO

O teste de ??) permite comparar formalmente o poder preditivo de dois modelos concorrentes. Sejam $L_t^{(1)} = (\hat{\sigma}_{1,t}^2 - \xi_t)^2$ e $L_t^{(2)} = (\hat{\sigma}_{2,t}^2 - \xi_t)^2$ as perdas (MSE) dos modelos 1 e 2, respectivamente. Define-se a diferença de perdas $d_t = L_t^{(1)} - L_t^{(2)}$ e testa-se:

$$H_0 : E[d_t] = 0 \quad (\text{igual poder preditivo}). \quad (2.21)$$

A estatística de Diebold–Mariano é:

$$DM = \frac{\bar{d}}{\sqrt{\widehat{\text{Var}}(\bar{d})}} \xrightarrow{d} \mathcal{N}(0, 1), \quad (2.22)$$

onde $\bar{d} = T^{-1} \sum_{t=1}^T d_t$ e $\widehat{\text{Var}}(\bar{d})$ é estimada com correção HAC (*Heteroskedasticity and Autocorrelation Consistent*) de Newey–West para horizonte de previsão h . Um valor DM negativo e estatisticamente significativo indica que o modelo 1 é superior; um valor positivo e significativo indica superioridade do modelo 2.

2.5.4 INTERVALOS DE CONFIANÇA BOOTSTRAP

Para construir intervalos de confiança para as métricas pontuais (MSE, MAE e QLIKE), emprega-se o método de **bootstrap percentil não-paramétrico** (??). O procedimento consiste em:

1. Formar B reamostras de tamanho T por sorteio com reposição dos pares $(\hat{\sigma}_t^2, \xi_t)$;
2. Para cada reamostra $b = 1, \dots, B$, calcular a métrica θ_b^* ;
3. Obter o intervalo de confiança $(1 - \alpha)$ pelos quantis da distribuição *bootstrap*:

$$\text{IC}_{1-\alpha} = [\hat{\theta}_{\alpha/2}^*, \hat{\theta}_{1-\alpha/2}^*], \quad (2.23)$$

onde $\hat{\theta}_q^*$ denota o quantil de ordem q da distribuição de $\{\theta_b^*\}_{b=1}^B$.

O *bootstrap* percentil é preferível à inferência assintótica baseada na distribuição normal neste contexto, pois as perdas de previsão de volatilidade são tipicamente assimétricas e de cauda pesada, violando as hipóteses de normalidade.

3 METODOLOGIA

Este capítulo descreve os procedimentos empíricos adotados para investigar o impacto do método de amostragem — *dollar bars* versus *time bars* — sobre a qualidade preditiva de modelos ARMA-GARCH para a variância condicional de retornos do par BTC/USDT. A exposição segue a ordem cronológica da *pipeline* de modelagem: coleta e preparação dos dados (??), análise exploratória das séries (??), construção dos retornos (??), divisão treino-teste (??), seleção de parâmetros via CPCV (??), estimação do modelo final (??), agregação das previsões para nível diário (??), avaliação por métricas e testes estatísticos (??) e implementação computacional (??).

3.1 DADOS E PERÍODO AMOSTRAL

O estudo utiliza dados de negociação do par BTC/USDT na *exchange* Binance, abrangendo o período de 1º de janeiro de 2024 a 31 de dezembro de 2025 (731 dias corridos). A partir dos dados brutos de alta frequência, foram construídas duas séries de barras com resolução efetiva equivalente a 5 minutos:

- **Dollar Bars (5 min):** 209.630 barras, amostradas sempre que o volume financeiro acumulado atinge um limiar $\bar{D}$ calibrado para produzir, em média, o mesmo número de barras por dia que as *time bars* de 5 minutos;
- **Time Bars (5 min):** 210.522 barras, amostradas em intervalos fixos de 5 minutos.

Adicionalmente, a volatilidade realizada diária, estimada pelo método TSRV (subseção 2.3.2), serve como *benchmark* para avaliação das previsões. O *benchmark* cobre os mesmos 731 dias do período amostral.

3.1.1 COLETA E PRÉ-PROCESSAMENTO DOS DADOS DE ALTA FREQUÊNCIA

Os dados brutos utilizados neste trabalho consistem nos registros de negociação agregada (*aggTrades*) do par BTC/USDT disponibilizados pela Binance. Cada observação contém o preço de execução da negociação, o volume transacionado e a direção do *taker* (campo *IsBuyerMaker*). O volume total do período amostral supera 1 bilhão de registros, distribuídos em arquivos no formato Apache Parquet com tamanho agregado de aproximadamente 28 GB.

Dado o volume de dados incompatível com o carregamento integral em memória principal (*RAM*), adotou-se uma arquitetura de processamento por *streaming*, descrita em detalhe a seguir.

3.1.1.1 ARQUITETURA DE PROCESSAMENTO POR *STREAMING* VIA *ROW GROUPS*

O formato Parquet organiza os dados em unidades lógicas denominadas *row groups* — blocos contíguos de linhas armazenados de forma colunar. A biblioteca `pyarrow` permite a leitura seletiva de um *row group* por vez, sem que o restante do arquivo seja desserializado. Essa característica foi explorada para implementar um laço de processamento iterativo: a cada iteração, um único *row group* é carregado em memória, as métricas de microestrutura são calculadas e acumuladas em estruturas de dados de tamanho fixo, e o bloco é então descartado antes que o próximo seja lido.

O resultado prático é um consumo de memória aproximadamente constante ao longo de toda a execução — empiricamente observado em torno de 500 MB — independentemente do tamanho total do arquivo. Tal abordagem é condição necessária para a replicabilidade do experimento em ambientes com recursos computacionais convencionais (ausência de infraestrutura de *cluster*), garantindo ao mesmo tempo que a íntegra dos dados seja processada sem amostragem prévia.

3.1.1.2 EXTRAÇÃO DO PREÇO EFICIENTE POR FILTRO IIR

No arcabouço de microestrutura, o preço observado P_t é decomposto em duas componentes:

$$P_t = P_t^* + \varepsilon_t, \quad (3.1)$$

onde P_t^* denota o *preço eficiente* — o valor fundamental latente do ativo, livre de ruído transacional — e ε_t representa o ruído de microestrutura, gerado pela descrição do *tick*, pelo *spread bid-ask* e por outros custos de transação.

Para extrair P_t^* , aplicou-se um filtro de Média Móvel Exponencial (EMA) de primeira ordem, equivalente a um filtro de Resposta ao Impulso Infinita (IIR) passa-baixas com função de transferência:

$$H(z) = \frac{\alpha}{1 - (1 - \alpha)z^{-1}}, \quad (3.2)$$

onde $\alpha \in (0, 1)$ é o coeficiente de suavização. A equação de recorrência correspondente é $P_t^* = \alpha P_t + (1 - \alpha)P_{t-1}^*$, que pode ser implementada de forma causal e eficiente via `scipy.signal.lfilter`. A denominação “IIR” sublinha que, ao contrário dos filtros de Resposta ao Impulso Finita (FIR), cada saída depende de toda a história passada da série, tornando a manutenção do *estado* do filtro entre os *row groups* processados indispensável para garantir a continuidade do sinal: ao final de cada bloco, o vetor de estado interno do filtro é preservado e injetado como condição inicial do bloco subsequente.

O componente de ruído é então estimado como o resíduo $\hat{\varepsilon}_t = P_t - \hat{P}_t^*$, e suas propriedades estatísticas — média, variância, percentis e perfil intradiário — são acumuladas nas estruturas *online* descritas nas subseções anteriores.

3.1.1.3 ACELERAÇÃO POR COMPILAÇÃO JIT VIA NUMBA

Os *kernels* de cálculo que envolvem laços internos sobre janelas móveis — em particular, o estimador de Hasbrouck e a covariância serial do modelo de Roll — foram decorados com a diretiva `@numba.njit` (modo *nopython*), que instrui o compilador Numba a traduzir o código Python para código de máquina LLVM sem intermediação do interpretador CPython. O resultado é desempenho equivalente ao de C para laços numéricos intensivos, com o benefício de manter a legibilidade e a verificabilidade do código em Python. O ganho de velocidade observado em relação ao NumPy puro para janelas de comprimento $\sim 10^4$ foi superior a uma ordem de grandeza, tornando o processamento da série completa viável em tempo compatível com o ciclo de pesquisa.

3.1.2 ESTIMAÇÃO DA VOLATILIDADE REALIZADA

A Volatilidade Realizada (RV) é uma medida não paramétrica da variância integrada de um processo de preços, obtida pela soma dos quadrados dos log-retornos observados em alta frequência (??). Para um ativo com preços $P_0, P_1, \dots, P_n$ amostrados a intervalos regulares, o estimador clássico é definido como:

$$\widehat{RV}_n = \sum_{i=1}^n r_i^2, \quad r_i = \ln\left(\frac{P_i}{P_{i-1}}\right). \quad (3.3)$$

Sob o modelo de difusão sem ruído, $\widehat{RV}_n$ converge em probabilidade para a variância integrada $\int_0^1 \sigma_s^2 ds$ quando $n \rightarrow \infty$. No entanto, dados de altíssima frequência como *aggTrades* da Binance são contaminados por ruído de microestrutura de mercado — originado pelo *bid-ask bounce*, pela discricção do *tick* e por custos de transação —, o que induz viés crescente em $\widehat{RV}_n$ à medida que a frequência de amostragem aumenta. Esse fenômeno é denominado o *bias-variance trade-off* da volatilidade realizada.

3.1.2.1 TWO-SCALE REALIZED VOLATILITY (TSRV)

Para contornar o viés imposto pelo ruído de microestrutura, adotou-se o estimador *Two-Scale Realized Volatility* (TSRV), proposto por ??). A ideia central é combinar duas escalas de observação: uma escala “grossa” (sub-grids), menos suscetível ao ruído, e a escala completa, que serve de base para a correção do viés.

Sejam n log-retornos calculados sobre preços amostrados a uma frequência regular. O estimador TSRV é construído em três etapas:

1. **RV na escala completa.** Calcula-se a RV clássica sobre todos os n retornos:

$$\widehat{RV}^{(\text{all})} = \sum_{i=1}^n r_i^2. \quad (3.4)$$

2. **Divisão em K sub-grids e RV média.** Os índices $\{1, \dots, n\}$ são particionados em K sub-grids, onde o sub-grid k contém os índices $\{k, k + K, k + 2K, \dots\}$. Para cada sub-grid k , calcula-se a RV parcial $\widehat{RV}^{(k)}$ a partir dos retornos entre observações consecutivas dentro do sub-grid. A média das K RVs parciais fornece:

$$\overline{RV}^{(K)} = \frac{1}{K} \sum_{k=1}^K \widehat{RV}^{(k)}. \quad (3.5)$$

3. **Correção de viés.** O estimador TSRV corrige o viés de ruído subtraindo uma fração da RV na escala completa:

$$\widehat{TSRV} = \overline{RV}^{(K)} - \frac{\bar{n}}{n} \widehat{RV}^{(\text{all})}, \quad (3.6)$$

onde $\bar{n} = n/K$ é o tamanho médio de cada sub-grid. A intuição é que o termo $(\bar{n}/n) \widehat{RV}^{(\text{all})}$ estima a contribuição do ruído à RV na escala completa, que é proporcional ao número de observações.

Determinação do K ótimo. ??) demonstram que o K que minimiza o erro quadrático médio assintótico do estimador é:

$$K^* = \lfloor n^{2/3} \rfloor, \quad (3.7)$$

onde $\lfloor \cdot \rfloor$ denota o arredondamento para o inteiro mais próximo. Na implementação, K é limitado superiormente por $\lfloor n/2 \rfloor$ para garantir que cada sub-grid contenha ao menos duas observações. O estimador final é truncado em zero ($\max(\widehat{TSRV}, 0)$) para garantir não-negatividade em amostras finitas.

3.1.2.2 AMOSTRAGEM EM TEMPO CALENDÁRIO

Os *ticks* brutos chegam em tempo de transação irregular, tornando necessária uma reestruturação temporal antes do cômputo da TSRV. Adotou-se a amostragem em tempo calendário (*calendar-time sampling*): para cada frequência Δ configurável (ex.: 30s, 1 min, 2 min), o preço correspondente a cada intervalo $[t, t + \Delta)$ é definido como o preço da *última* transação executada naquele intervalo (`resample( $\Delta$ ).last()`). Intervalos sem negociação são descartados (`dropna()`). Esse procedimento produz uma grade temporal regular de preços $P_1, P_2, \dots, P_n$ sobre a qual os log-retornos são calculados via diferenciação logarítmica: $r_i = \ln(P_i) - \ln(P_{i-1})$.

3.1.2.3 PROCESSAMENTO DIÁRIO EFICIENTE (TICKDATAPROCESSOR)

Dado o volume de dados (superior a 1 bilhão de registros), o processamento é realizado dia a dia. A classe `TickDataProcessor` encapsula a leitura seletiva de dados do arquivo Parquet via filtros aplicados diretamente no disco (`pyarrow.parquet.read_parquet` com predicado de intervalo de datas), carregando em memória apenas as colunas `DateTime`, `Price` e `Qty` referentes a um único dia de negociação. Para cada dia, a função `compute_daily_rv` realiza: (i) a reestruturação temporal por reamostragem; (ii) a instanciação da classe `TwoScaleRV` sobre o vetor de preços resultante; e (iii) o cômputo do estimador com coleta de estatísticas auxiliares — número de *ticks*, número de observações amostradas, volume financeiro e preço médio.

3.1.2.4 BENCHMARK DE CONSENSO MULTI-FREQUÊNCIA

A escolha da frequência de reamostragem Δ introduz um grau de arbitrariedade nas estimativas de TSRV. Para mitigar esse efeito, construiu-se um *benchmark* de consenso: a *pipeline* `compute_rv_series` é executada independentemente para três frequências — 30 segundos, 1 minuto e 2 minutos — gerando três séries diárias de RV, denotadas $\widehat{TSRV}_{30s,d}$, $\widehat{TSRV}_{1min,d}$ e $\widehat{TSRV}_{2min,d}$. O benchmark de consenso para o dia d é então definido como a média aritmética dessas três estimativas:

$$\widehat{RV}_{\text{consenso},d} = \frac{1}{3} \left(\widehat{TSRV}_{30s,d} + \widehat{TSRV}_{1min,d} + \widehat{TSRV}_{2min,d} \right), \quad (3.8)$$

com dias em que qualquer das três frequências produziu valor ausente (`NaN`) tratados de forma robusta pela média sobre os valores disponíveis. Essa abordagem reduz a sensibilidade do benchmark a escolhas arbitrárias de Δ e fornece uma medida mais estável da variância integrada diária.

A volatilidade anualizada correspondente é obtida por:

$$\hat{\sigma}_{\text{anual},d} = \sqrt{\widehat{RV}_{\text{consenso},d} \times 252}. \quad (3.9)$$

3.2 ANÁLISE EXPLORATÓRIA DAS SÉRIES

Antes de proceder à modelagem, realizou-se uma análise exploratória das séries completas de retornos logarítmicos, com o objetivo de verificar as premissas dos modelos ARMA-GARCH e identificar diferenças distribucional e de dependência entre os dois métodos de amostragem.

3.2.1 ESTATÍSTICAS DESCRITIVAS

Calcularam-se os quatro primeiros momentos amostrais da distribuição dos retornos — média, variância, assimetria e curtose de Fisher — para ambos os tipos de barra, sobre a

série completa (209.630 observações para *dollar bars* e 210.522 para *time bars*). A curtose é o indicador diagnóstico central deste trabalho: a literatura de microestrutura prevê que *dollar bars* produzem retornos com caudas menos pesadas do que *time bars* de igual resolução efetiva, dado que a amostragem por volume financeiro redistribui choques de alta atividade ao longo de múltiplas barras, em vez de comprimi-los em uma única observação temporal (??). Os resultados das estatísticas descritivas são apresentados e discutidos no ??.

3.2.2 TESTES DE NORMALIDADE, ESTACIONARIEDADE E HETEROSCEDASTICIDADE

Para verificar formalmente as premissas dos modelos ARMA-GARCH, aplicaram-se os seguintes testes estatísticos às séries de retornos logarítmicos:

1. **Normalidade:** testes de Jarque-Bera e Kolmogorov-Smirnov, ambos com hipótese nula de distribuição gaussiana. A não-normalidade é um fato estilizado amplamente documentado em retornos financeiros de alta frequência (??), com implicações diretas sobre a especificação da distribuição condicional nos modelos GARCH;
2. **Estacionariedade:** Teste Dickey-Fuller Aumentado (ADF), com hipótese nula de raiz unitária, e Teste KPSS, com hipótese nula de estacionariedade. A confirmação de estacionariedade das séries de retornos é condição necessária para a validade dos modelos ARMA-GARCH sem diferenciação ($d = 0$), pois a presença de raiz unitária invalidaria a inferência assintótica padrão;
3. **Autocorrelação e efeitos ARCH:** Teste de Ljung-Box aplicado aos retornos em nível (r_t) e aos retornos ao quadrado (r_t^2), ambos com 10 defasagens, e Teste ARCH de Engle com 10 defasagens, com hipótese nula de ausência de heteroscedasticidade condicional. A presença de efeitos ARCH nos retornos ao quadrado constitui a principal justificativa empírica para o uso de modelos da família GARCH.

Os resultados dos testes, os histogramas com curva normal ajustada, os QQ-plots e as funções de autocorrelação (FAC e FACP) dos retornos ao quadrado são apresentados no ??.

3.3 CONSTRUÇÃO DOS RETORNOS LOGARÍTMICOS

Para cada série de barras, os retornos logarítmicos foram calculados como:

$$r_t = \ln \left(\frac{C_t}{C_{t-1}} \right), \quad (3.10)$$

onde C_t denota o preço de fechamento da t -ésima barra. A primeira observação de cada série é descartada (r_1 é indefinido), resultando em 209.629 retornos para *dollar bars* e 210.521 para *time bars*.

A opção por retornos logarítmicos em vez de retornos simples ($R_t = C_t/C_{t-1} - 1$) justifica-se por duas razões: (i) retornos logarítmicos são aditivos ao longo do tempo, facilitando a agregação temporal de variâncias; e (ii) para retornos de pequena magnitude, como é o caso de barras de 5 minutos, $r_t \approx R_t$, de modo que a escolha é praticamente irrelevante numericamente.

3.4 DIVISÃO TREINO-TESTE

A amostra total de cada série foi dividida em dois conjuntos por meio de um *split* temporal na proporção 80%/20%, preservando a ordem cronológica dos dados. A ?? resume as dimensões e períodos de cada partição.

Tabela 1 – Divisão treino-teste por tipo de barra.

Série	Partição	Observações		Período
<i>Dollar Bars</i>	Treino (80%)	167.704	01/jan/2024 – 14/jul/2025	
	Teste (20%)	41.926	14/jul/2025 – 31/dez/2025	
<i>Time Bars</i>	Treino (80%)	168.417	01/jan/2024 – 07/ago/2025	
	Teste (20%)	42.105	07/ago/2025 – 31/dez/2025	

Fonte: Elaboração própria.

Observa-se que as datas de corte diferem ligeiramente entre os dois tipos de barra (14 de julho vs. 7 de agosto de 2025), uma vez que a proporção 80%/20% é definida sobre o número de barras, e não sobre o calendário. Isso é esperado, pois as *dollar bars* possuem espaçamento temporal irregular.

É importante ressaltar que a divisão treino-teste é distinta do procedimento de validação cruzada CPCV descrito na ??: o CPCV opera exclusivamente sobre o conjunto de **treino** para selecionar os hiperparâmetros, enquanto o conjunto de **teste** é reservado para a avaliação final do modelo selecionado.

3.5 SELEÇÃO DE PARÂMETROS VIA CPCV

A seleção das ordens ótimas (p, q) para a equação da média (ARMA) e (r, s) para a equação da variância (GARCH) foi realizada pelo arcabouço de Validação Cruzada Combinatória Purgada (CPCV), descrito na ?. Este procedimento foi aplicado exclusivamente ao conjunto de treino de cada série.

3.5.1 CONFIGURAÇÃO DO CPCV

O CPCV foi configurado com os seguintes parâmetros:

- **Número de grupos:** $N = 10$ (o conjunto de treino é dividido em 10 blocos sequenciais);
- **Grupos de teste:** $k = 5$ (a cada partição, 5 grupos compõem o teste);
- **Número de folds:** $\binom{10}{5} = 252$ partições treino-teste distintas;
- **Embargo:** 240 barras (≈ 20 horas em barras de 5 min) após cada bloco de teste, mitigando vazamento por autocorrelação serial.

Em cada fold, as observações situadas na fronteira entre os blocos de treino e teste são removidas (purgação), e as 240 barras subsequentes ao final de cada bloco de teste são embargadas, conforme o procedimento descrito na ???. Em média, cada fold utiliza aproximadamente 81.500 observações para treino e 84.000 para teste, com cerca de 1.200 observações purgadas e 1.200 embargadas.

3.5.2 GRID DE BUSCA

O espaço de busca compreende o produto cartesiano:

$$\text{ARMA}(p, q) \times \text{GARCH}(r, s), \quad p, q \in \{0, 1, \dots, 5\}, \quad r \in \{1, 2\}, \quad s \in \{1, 2\}, \quad (3.11)$$

totalizando $6 \times 6 \times 2 \times 2 = 144$ combinações de parâmetros. Para cada uma das 252 partições CPCV, todas as 144 combinações foram estimadas por máxima verossimilhança (MV), resultando em $252 \times 144 = 36.288$ ajustes MLE por tipo de barra e 72.576 ajustes no total da *pipeline*.

O critério de seleção em cada fold é o AIC (Equação 2.5): a combinação com o menor AIC no conjunto de validação do fold é registrada como “vencedora”. Ao final dos 252 folds, o modelo selecionado é aquele cuja combinação de parâmetros obteve a maior *frequência* de vitórias — ou seja, a moda da distribuição de modelos selecionados ao longo dos folds.

Os modelos selecionados pelo CPCV — identificados pela moda da distribuição de frequências de vitórias ao longo dos 252 *folds* — são apresentados e discutidos no ???.

3.6 ESTIMAÇÃO DO MODELO FINAL

Após a seleção de parâmetros, o modelo final de cada série foi reestimado utilizando **todo** o conjunto de treino (sem particionamento CPCV), a fim de maximizar a precisão

dos coeficientes estimados. Os critérios de informação do ajuste final (AIC e BIC) são reportados no ??.

A partir do modelo estimado, realizou-se a previsão *one-step-ahead* da variância condicional $\hat{\sigma}_t^2$ para cada observação do conjunto de teste.

3.7 AGREGAÇÃO PARA NÍVEL DIÁRIO

Como a volatilidade realizada (RV) de referência é calculada em base diária, as previsões intradiárias de variância condicional precisam ser agregadas ao nível diário para permitir comparação direta. A agregação segue o princípio de aditividade da variância de retornos logarítmicos independentes: a variância diária prevista é obtida pela soma das variâncias condicionais intradiárias dentro de cada dia:

$$\hat{\sigma}_{\text{dia},d}^2 = \sum_{t \in \mathcal{B}_d} \hat{\sigma}_t^2, \quad (3.12)$$

onde $\mathcal{B}_d$ denota o conjunto de barras pertencentes ao dia d .

Após a agregação e o alinhamento com o *benchmark* de volatilidade realizada, obtiveram-se:

- **Dollar Bars:** 171 dias com previsão (14/jul/2025 a 31/dez/2025), todos alinhados com o RV *benchmark*;
- **Time Bars:** 147 dias com previsão (07/ago/2025 a 31/dez/2025), todos alinhados com o RV *benchmark*.

A diferença na quantidade de dias (171 vs. 147) decorre das datas distintas de início do conjunto de teste para cada tipo de barra, conforme discutido na ??. Para garantir comparabilidade estrita entre os modelos, a avaliação final das métricas, os intervalos de confiança e o teste de Diebold-Mariano foram calculados exclusivamente sobre a **interseção** dos dois períodos: os **147 dias comuns** compreendidos entre 07/ago/2025 e 31/dez/2025.

3.8 MÉTRICAS DE AVALIAÇÃO E TESTES ESTATÍSTICOS

As previsões diárias de variância foram avaliadas contra o *benchmark* de volatilidade realizada (RV consenso, [subseção 2.3.2](#)) utilizando as métricas e testes descritos na ??. Esta seção detalha a parametrização específica empregada.

3.8.1 FUNÇÕES DE PERDA E REGRESSÃO MINCER-ZARNOWITZ

Foram calculadas três funções de perda — MSE (??), MAE (??) e QLIKE (??) — sobre os pares $(\hat{\sigma}_{\text{dia},d}^2, \xi_d)$ para cada tipo de barra, onde ξ_d denota a volatilidade realizada diária do *benchmark*.

A regressão de Mincer-Zarnowitz (??) foi estimada por MQO, fornecendo o coeficiente de determinação R^2 , o intercepto α e a inclinação β , com seus respectivos p -valores.

Os resultados comparativos das três funções de perda são apresentados no ??.

3.8.2 TESTE DE DIEBOLD-MARIANO

Para comparar formalmente o poder preditivo dos dois modelos, aplicou-se o teste de Diebold-Mariano (??) com a função de perda MSE. A hipótese nula é de igual poder preditivo entre o modelo ajustado sobre *dollar bars* e o ajustado sobre *time bars*. O teste foi calculado sobre o subconjunto de dias em que ambos os modelos possuem previsões, com correção HAC de Newey-West. Os resultados são reportados no ??.

3.8.3 INTERVALOS DE CONFIANÇA BOOTSTRAP

Intervalos de confiança de 95% para as métricas pontuais foram construídos pelo método de *bootstrap* percentil não-paramétrico (??) com $B = 2.000$ reamostras. Os intervalos resultantes são apresentados e discutidos no ??.

4 RESULTADOS E DISCUSSÃO

4.1 PROPRIEDADES ESTATÍSTICAS COMPARATIVAS DAS SÉRIES

A análise exploratória das séries de retornos logarítmicos revela diferenças estruturais substanciais entre as duas formas de amostragem, conforme sintetizado na ???. Essas diferenças não são ruído amostral: elas decorrem diretamente do mecanismo pelo qual cada tipo de barra é construída.

Tabela 2 – Estatísticas descritivas dos retornos logarítmicos.

Estatística	<i>Dollar Bars</i>	<i>Time Bars</i>
Média (1° momento)	3.46×10^{-6}	3.44×10^{-6}
Variância (2° momento)	2.49×10^{-6}	2.40×10^{-6}
Assimetria (3° momento)	0.0547	-1.0071
Curtose de Fisher (4° momento)	3.0879	75.3687

Fonte: Elaboração própria.

O indicador mais expressivo é a curtose. As time bars de 5 minutos apresentam curtose de Fisher de 75,37, ao passo que as dollar bars registram apenas 3,09 — uma razão de aproximadamente 25 vezes. Para compreender essa disparidade, é preciso considerar o que ocorre durante choques de volatilidade no mercado de Bitcoin. Ao longo de um episódio de alta atividade financeira, dezenas de transações são comprimidas em uma única barra temporal, produzindo retornos extremamente grandes que inflariam artificialmente as caudas da distribuição. A dollar bar, ao encerrar uma barra sempre que o volume financeiro transacionado atinge o limiar $\bar{D}$, redistribui esse mesmo choque ao longo de múltiplas barras, diluindo o extremo. Esse mecanismo é precisamente a sub-amostragem em períodos de alta atividade descrita por ???) na discussão sobre barras de informação (seção 2.1.1).

A assimetria reforça o mesmo argumento. Enquanto as dollar bars exibem assimetria de apenas 0,05 — praticamente simétrica —, as time bars apresentam assimetria de -1,01. O sinal negativo indica que quedas abruptas são capturadas de forma concentrada nessa amostragem: grandes retornos negativos, correspondentes a correções rápidas, tendem a ocorrer em janelas de poucos minutos e, por isso, se concentram em uma única barra temporal. Além da implicação distribucional, a simetria das dollar bars facilita a especificação do modelo GARCH, que, em sua formulação padrão com inovações gaussianas, assume distribuição condicional simétrica.

Tabela 3 – Testes de normalidade, estacionariedade e heteroscedasticidade sobre os retornos logarítmicos.

Teste	<i>Dollar Bars</i>		<i>Time Bars</i>	
	Estat.	<i>p</i> -valor	Estat.	<i>p</i> -valor
Jarque-Bera	83 384.65	< 0,001	49 860 565.37	< 0,001
Kolmogorov-Smirnov	0.0123	< 0,001	0.0934	< 0,001
ADF	−102.46	< 0,001	−57.32	< 0,001
KPSS	0.2053	0.10	0.2171	0.10
Ljung-Box (r_t , lag 10)	50.06	< 0,001	155.03	< 0,001
Ljung-Box (r_t^2 , lag 10)	79 528.20	< 0,001	28 237.22	< 0,001
ARCH de Engle (lag 10)	30 420.71	< 0,001	24 064.78	< 0,001

Nota: H_0 por teste: Jarque-Bera e KS — normalidade; ADF — raiz unitária; KPSS — estacionariedade; Ljung-Box e ARCH de Engle — ausência de autocorrelação/efeito ARCH.

Fonte: Elaboração própria.




Figura 2 – Histograma com curva normal e QQ-Plot — Dollar Bars (5 min).




Figura 3 – Histograma com curva normal e QQ-Plot — Time Bars (5 min).




Figura 4 – ACF e PACF dos retornos ao quadrado — Dollar Bars (5 min).




Figura 5 – ACF e PACF dos retornos ao quadrado — Time Bars (5 min).

Os testes formais de adequação distribucional, apresentados na ??, amplificam esse quadro. A estatística de Jarque-Bera das time bars é superior a 49 milhões, contra aproximadamente 83 mil para as dollar bars — uma diferença de mais de 500 vezes. Esse resultado não representa apenas rejeição da normalidade, que ambas as séries exibem: indica que as caudas das time bars pertencem a uma ordem de magnitude distinta. O teste de Ljung-Box nos retornos em nível rejeita a hipótese de ausência de autocorrelação para as duas séries, mas com estatística consideravelmente maior para as time bars (155,03 versus 50,06). Contudo, conforme discutido na seção seguinte, essa autocorrelação é de magnitude modesta para o volume de observações disponível e não justifica componentes autorregressivos ou de médias móveis no modelo final. Ambas as séries são estacionárias: o teste Dickey-Fuller Aumentado rejeita a hipótese de raiz unitária, e o teste KPSS não rejeita estacionariedade em nenhuma das duas amostras, validando o uso de $d = 0$ na especificação ARMA.

Em conjunto, os resultados exploratórios corroboram a hipótese de ??): dollar bars produzem séries com propriedades distribucionais superiores em termos de curtose, assimetria e dependência linear residual. Cabe ressaltar, contudo, que propriedades

descritivas melhores não garantem, por si só, maior poder preditivo fora da amostra. Essa questão é investigada nas seções seguintes.

4.2 SELEÇÃO DE MODELOS VIA CPCV

O procedimento de seleção de hiperparâmetros via *Combinatorial Purged Cross-Validation* (CPCV) com $N = 10$ grupos, $K = 5$ grupos de teste e embargo de 240 barras gerou $\binom{10}{5} = 252$ folds de avaliação, totalizando 36.288 ajustes MLE por série (252 folds $\times$ 144 combinações de parâmetros no grid $\text{ARMA}(0..5, 0..5) \times \text{GARCH}(1..2, 1..2)$).

Tabela 4 – Resultados da seleção de parâmetros via CPCV.

Série	Modelo selecionado	Frequência	AIC médio
<i>Dollar Bars</i>	ARMA(0,0)-GARCH(1,2)	233/252 (92,5%)	−835.475
<i>Time Bars</i>	ARMA(0,0)-GARCH(1,1)	252/252 (100%)	−859.083

Fonte: Elaboração própria.




Figura 6 – AIC médio por fold CPCV — Dollar Bars vs. Time Bars.

Em ambas as séries, o componente ARMA selecionado foi $\text{ARMA}(0,0)$, ou seja, média constante sem termos autorregressivos nem de médias móveis. Esse resultado é consistente com a hipótese de eficiência de mercado na forma fraca: os retornos do par BTC/USDT, a despeito de sua curtose elevada, não apresentam estrutura linear preditível suficiente para justificar a inclusão de termos AR ou MA. É importante observar que esse resultado não contradiz a rejeição do Ljung-Box reportada na seção anterior. As autocorrelações detectadas são de magnitude prática pequena — estatísticas de 50 e 155 para séries com cerca de 200 mil observações representam efeitos de baixa amplitude — e concentram-se, sobretudo, nos retornos ao quadrado, não nos níveis; o componente GARCH é o mecanismo mais adequado para capturá-las.

O resultado mais informativo da seleção refere-se ao componente GARCH. Para as dollar bars, o modelo GARCH(1, 2) — com um termo de inovação ao quadrado (α_1) e dois termos de variância defasada (β_1, β_2) — foi escolhido em 233 dos 252 folds, correspondendo a 92,5% de frequência de seleção. Para as time bars, o modelo GARCH(1, 1) canônico foi selecionado na totalidade dos 252 folds (100,0%). O AIC médio das time bars ao longo dos folds foi de -859.083 , contra -835.475 para as dollar bars, indicando melhor ajuste *in-sample* para a série temporal.

A necessidade de um termo β_2 adicional nas dollar bars tem uma interpretação econômica plausível. Por construção, as dollar bars possuem espaçamento temporal irregular: são geradas em maior número durante períodos de alta atividade financeira, quando a volatilidade do mercado é tipicamente mais elevada. Esse mecanismo faz com que os choques de volatilidade sejam distribuídos ao longo de mais barras, tornando o decaimento da variância condicional mais gradual e demandando uma especificação ligeiramente mais rica para capturá-lo adequadamente. As time bars, ao ignorar esse padrão de irregularidade temporal, comprimem os choques em barras únicas e produzem uma dinâmica de volatilidade mais diretamente capturada pelo GARCH(1, 1) canônico.

A estabilidade das seleções merece atenção. O fato de o GARCH(1, 1) ter sido eleito em 100% dos folds para as time bars indica que a dinâmica de volatilidade dessa série é bem descrita pela especificação padrão da literatura, com pouca ambiguidade quanto à ordem. Para as dollar bars, a frequência de 92,5% tampouco é marginal: denota robustez do GARCH(1, 2), não um artefato de um fold específico. Em síntese, o CPCV entregou seleções estáveis para ambas as séries, com a diferença de especificação entre elas refletindo uma propriedade genuína das dinâmicas de volatilidade subjacentes.

Cabe destacar que ajuste *in-sample* superior não implica, necessariamente, melhor desempenho preditivo fora da amostra — distinção fundamental em qualquer avaliação de modelos de previsão (??). Essa questão é endereçada diretamente na seção seguinte.

A ?? apresenta os critérios de informação do modelo final estimado sobre o conjunto de treino completo.

Tabela 5 – Critérios de informação do modelo final estimado sobre o conjunto de treino completo.

Série	Modelo	AIC	BIC
<i>Dollar Bars</i>	GARCH(1,2)	$-1\,693\,794.21$	$-1\,693\,744.06$
<i>Time Bars</i>	GARCH(1,1)	$-1\,742\,053.06$	$-1\,742\,012.92$

Fonte: Elaboração própria.

4.3 DESEMPENHO PREDITIVO FORA DA AMOSTRA

Esta seção constitui o núcleo analítico do trabalho, respondendo diretamente à pergunta de pesquisa com base nas métricas calculadas sobre os conjuntos de teste — 171 dias para as dollar bars (2025-07-14 a 2025-12-31) e 147 dias para as time bars (2025-08-07 a 2025-12-31) — e comparadas contra o estimador TSRV de volatilidade realizada como benchmark.

4.3.1 MÉTRICAS PONTUAIS

Tabela 6 – Métricas de avaliação das previsões de variância vs. RV *benchmark*.

Métrica	<i>Dollar Bars</i>	<i>Time Bars</i>
MSE	1.05×10^{-7}	1.65×10^{-7}
MAE	2.64×10^{-4}	3.59×10^{-4}
QLIKE	-6.993	-6.776
R^2_{MZ}	0.667	0.493
$\hat{\alpha}$	-9.20×10^{-5}	-2.54×10^{-4}
$\hat{\beta}$	0.868	1.032

Fonte: Elaboração própria.

As métricas de avaliação pontual, apresentadas na ??, revelam dominância das dollar bars nas três funções de perda avaliadas. O Erro Quadrático Médio (MSE) das dollar bars é de $1,05 \times 10^{-7}$, contra $1,65 \times 10^{-7}$ para as time bars — uma redução de aproximadamente 36%. O Erro Absoluto Médio (MAE) exibe comportamento análogo: $2,64 \times 10^{-4}$ versus $3,59 \times 10^{-4}$, representando redução de aproximadamente 26%. A métrica QLIKE, cujos valores menores (em módulo, mais negativos) indicam melhor desempenho, registra -6,993 para as dollar bars e -6,776 para as time bars, uma diferença de aproximadamente 0,22 em magnitude absoluta.

As três métricas pertencem à classe de funções de perda robustas de ??), cuja propriedade fundamental é preservar o ranking entre previsões de volatilidade mesmo quando o benchmark utilizado como variável dependente é um proxy ruidoso da volatilidade latente verdadeira. Essa propriedade é particularmente relevante no presente contexto, pois o estimador TSRV, ainda que consistente, incorpora ruído de microestrutura e incerteza de estimação que o afastam da variância quadrática integrada teórica. O fato de as três métricas robustas apontarem unanimemente na mesma direção reforça a confiabilidade do resultado.

4.3.2 REGRESSÃO DE MINCER-ZARNOWITZ

A regressão de Mincer-Zarnowitz (??), que regride a volatilidade realizada diária $\hat{\sigma}_{RV,t}^2$ sobre a previsão do modelo $\hat{h}_t$, fornece um diagnóstico adicional sobre a qualidade e o viés das previsões. Para as dollar bars, o coeficiente de determinação R^2 foi de 0,667 e o intercepto estimado de $\hat{\alpha} = -9,17 \times 10^{-5}$ (p-valor = 0,0168). Para as time bars, $R^2 = 0,493$ e $\hat{\alpha} = -2,54 \times 10^{-4}$ (p-valor = 0,0001).

O modelo baseado em dollar bars explica, portanto, 66,7% da variação da volatilidade realizada diária, contra 49,3% para as time bars. Essa diferença de aproximadamente 17,4 pontos percentuais no R^2 é economicamente relevante: para aplicações de gestão de risco, como o cálculo de VaR (*Value at Risk*) ou a otimização de carteiras com restrições de variância, modelos que explicam maior parcela da variação da volatilidade realizada tendem a produzir limites de risco mais calibrados (??).

Ambos os interceptos são negativos e estatisticamente significativos (a 5% para dollar bars e 1% para time bars), indicando leve subestimação sistemática da volatilidade realizada por parte de ambos os modelos. Esse resultado é típico de modelos GARCH paramétricos estimados com inovações gaussianas quando comparados a estimadores não-paramétricos de alta frequência: o estimador TSRV captura componentes de variação intrajornada que o GARCH, por ser estimado sobre retornos diários ou intradiários agregados, não incorpora diretamente. O coeficiente angular $\hat{\beta}$ foi de 0,868 para as dollar bars (p-valor < 0,001) e de 1,032 para as time bars (p-valor < 0,001), sugerindo que o modelo de dollar bars tende a subestimar levemente a resposta da volatilidade realizada à previsão, enquanto o de time bars apresenta resposta ligeiramente acima da unidade, indicando leve sobre-reação relativa.

4.3.3 TESTE DE DIEBOLD-MARIANO

A comparação formal de capacidade preditiva foi realizada por meio do teste de Diebold-Mariano (??). A estatística DM calculada sobre o subconjunto de 147 dias em que ambos os modelos produzem previsões sobrepostas foi de $-4,806$, com p-valor bilateral inferior a 0,001.

A interpretação desse resultado é direta e inequívoca. O sinal negativo da estatística DM confirma que o modelo estimado com dollar bars apresenta perdas (MSE) significativamente menores, em média, do que o modelo ajustado sobre time bars. O p-valor substancialmente menor que os níveis de significância convencionais (1%, 5% e 10%) permite rejeitar com contundência a hipótese nula de igual capacidade preditiva.

O fato de a rejeição ser estatisticamente forte mesmo em uma amostra de teste relativamente curta (147 dias de sobreposição) reforça a consistência da superioridade preditiva das dollar bars evidenciada pelas métricas pontuais. Em termos práticos, a

redução de aproximadamente 36% no MSE não é um mero artefato amostral, mas uma diferença de desempenho estrutural e significativa que pode se traduzir em melhorias relevantes para gestão de risco, alocação de carteiras ou precificação de derivativos.

4.3.4 INTERVALOS DE CONFIANÇA BOOTSTRAP

Tabela 7 – Intervalos de confiança bootstrap (95%) para as métricas de avaliação.

Série	Métrica	Pontual	IC 95%	SE
<i>Dollar Bars</i>	MSE	1.050×10^{-7}	[7,34e-8; 1,49e-7]	1.93e-8
	MAE	2.637×10^{-4}	[2,35e-4; 2,97e-4]	1.59e-5
	QLIKE	-6.993	[-7,137; -6,845]	7.48e-2
<i>Time Bars</i>	MSE	1.645×10^{-7}	[1,35e-7; 2,00e-7]	1.66e-8
	MAE	3.588×10^{-4}	[3,29e-4; 3,90e-4]	1.56e-5
	QLIKE	-6.776	[-6,877; -6,668]	5.38e-2

Nota: Valores calculados sobre os 147 dias comuns (07/ago/2025–31/dez/2025). $B = 2.000$ reamostras; IC pelo método percentil.

Fonte: Elaboração própria.

Os intervalos de confiança de 95% obtidos por bootstrap com $n_{\text{boot}} = 2000$ reamostras, apresentados na ??, complementam a conclusão do teste DM ao fornecer a margem de incerteza para cada modelo separadamente.

Para o MSE, os intervalos se sobrepõem ligeiramente: o IC 95% do MSE das dollar bars é $[7,34 \times 10^{-8}, 1,49 \times 10^{-7}]$, enquanto o das time bars é $[1,35 \times 10^{-7}, 2,00 \times 10^{-7}]$. Essa leve sobreposição não invalida a conclusão do teste DM, mas reflete a grande variância do MSE, que penaliza quadraticamente grandes desvios e, portanto, é mais sensível a extremos em pequenas amostras. Contudo, para o MAE, que é uma métrica absoluta menos suscetível a *outliers*, os intervalos **não se sobrepõem**: dollar bars em $[2,34 \times 10^{-4}, 2,97 \times 10^{-4}]$ e time bars em $[3,29 \times 10^{-4}, 3,90 \times 10^{-4}]$. Isso demonstra que a previsão de dollar bars também possui uma acurácia mediana sistematicamente superior.

O resultado mais robusto do presente trabalho emerge da análise dos intervalos de confiança para a métrica QLIKE. O IC 95% das dollar bars é $[-7,137, -6,845]$, e o das time bars é $[-6,877, -6,668]$. Esses intervalos **não se sobrepõem**, o que significa que, com 95% de confiança, a métrica QLIKE das dollar bars é menor do que a das time bars. A relevância desse achado é amplificada pelo fato de o QLIKE ser, entre as três funções de perda avaliadas, a mais adequada do ponto de vista teórico para comparar previsões de volatilidade: conforme demonstrado por ??), é a única função de perda da família que é robusta ao uso de proxies ruidosos e que ao mesmo tempo possui propriedades de elicitação para a variância condicional.

Em síntese, o conjunto de evidências — estatística DM negativa e significativa a menos de 1%, ICs de MAE e QLIKE não sobrepostos a 95%, e dominância simultânea em MSE, MAE, QLIKE e R^2 MZ — constitui evidência consistente, formal e coerente em favor das dollar bars como insumo para modelos GARCH de previsão de volatilidade do BTC/USDT. A superioridade preditiva documentada é substancial em magnitude e perfeitamente amparada pela estatística.

4.4 LIMITAÇÕES E RESSALVAS

A interpretação dos resultados deve ser contextualizada por um conjunto de limitações metodológicas e de escopo que delimitam o alcance das conclusões.

4.4.0.0.1 Ativo único.

Todos os resultados são obtidos para o par BTC/USDT negociado na Binance. Criptomoedas operam 24 horas por dia, sete dias por semana, e possuem microestrutura distinta de mercados regulados: ausência de mecanismos de circuit breaker, inexistência de leilão de abertura e fechamento, e liquidez fragmentada entre múltiplas exchanges. Essas características tornam o BTC/USDT um caso de análise com dinâmicas próprias, e a generalização dos resultados para ações, câmbio ou commodities demanda estudos adicionais com esses ativos.

4.4.0.0.2 Período amostral.

O horizonte de dois anos (2024–2025) é suficiente para estimação e validação dos modelos, mas pode não capturar toda a variação de regimes de volatilidade relevantes para o Bitcoin. O período abrange fases de bull e bear market, mas parâmetros estimados sobre esse intervalo podem não ser estáveis em regimes futuros com características distintas das observadas.

4.4.0.0.3 Calibração do limiar $\bar{D}$.

O limiar das dollar bars foi calibrado para produzir o mesmo número médio de barras por dia que as time bars de 5 minutos, tornando as comparações controladas por volume de observação. Essa escolha é metodologicamente razoável, mas arbitrária: resultados poderiam diferir com limiares maiores ou menores, que gerariam séries com granularidade distinta e, possivelmente, propriedades distribucional diferentes.

4.4.0.0.4 Distribuição dos erros.

Ambos os modelos foram estimados com inovações gaussianas. Diante do excesso de curtose documentado — especialmente expressivo nas time bars — distribuições de cauda pesada, como a t-Student ou a Distribuição de Erro Generalizado (GED), poderiam melhorar o ajuste e potencialmente alterar a magnitude e o sentido das diferenças entre os modelos.

4.5 SÍNTESE DO CAPÍTULO

Em conjunto, os resultados indicam que dollar bars produzem séries de retornos com propriedades estatísticas superiores e modelos GARCH com maior poder preditivo fora da amostra para o BTC/USDT no período 2024–2025. A evidência é consistente em direção — dominância em MSE, MAE, QLIKE e R^2 MZ — e materialmente relevante em magnitude, com reduções de 36% no MSE e de 26% no MAE, e uma diferença de 17,4 pontos percentuais no coeficiente de determinação da regressão de Mincer-Zarnowitz. A significância estatística formal é inequívoca: o teste de Diebold-Mariano rejeita a hipótese de igualdade preditiva a um nível de significância inferior a 1% ($p < 0,001$). Adicionalmente, a análise dos intervalos de confiança bootstrap não paramétricos para o MAE e para o QLIKE — esta última, a métrica teoricamente mais adequada para estimação da variância — revela intervalos de 95% que sequer se sobrepõem, atestando em definitivo a vantagem das dollar bars sobre a amostragem em tempo para o ativo e período em questão.

5 CONCLUSÃO

5.1 RETOMADA DOS OBJETIVOS ESPECÍFICOS

Esta seção retoma os cinco objetivos específicos enunciados na seção 1.1.2 e avalia sua consecução à luz dos resultados obtidos.

O primeiro objetivo — construir séries de retornos a partir de time bars e dollar bars e comparar suas propriedades estatísticas — foi plenamente atingido. As dollar bars produziram retornos com curtose de Fisher de 3,09, contra 75,37 das time bars, uma redução de cerca de 25 vezes. A assimetria das dollar bars foi de 0,05, próxima de zero, enquanto as time bars registraram $-1,01$. Esses resultados confirmam quantitativamente as previsões de ??) sobre o efeito do mecanismo de amostragem nas propriedades distribucionais dos retornos.

O segundo objetivo — estimar a variância realizada por meio do estimador TSRV — também foi atingido. O estimador *Two-Scale Realized Variance* foi calculado sobre dados *tick-by-tick* com três frequências de subamostragem (30 segundos, 1 minuto e 2 minutos), e a média dos três estimadores foi utilizada como benchmark de volatilidade diária. O procedimento de múltiplas escalas reduz o viés introduzido pelo ruído de microestrutura, produzindo um estimador consistente da variância quadrática integrada (??).

O terceiro objetivo — ajustar modelos ARMA-GARCH e selecionar ordens ótimas via critérios de informação — foi atingido. O CPCV com 252 folds selecionou o modelo ARMA(0, 0)-GARCH(1, 2) para as dollar bars, com frequência de 92,5% dos folds (233/252), e o modelo ARMA(0, 0)-GARCH(1, 1) para as time bars, com frequência de 100% dos folds (252/252). Em ambos os casos, a seleção foi estável e robusta ao longo dos folds.

O quarto objetivo — avaliar e comparar o desempenho preditivo com MSE, MAE, QLIKE e a regressão de Mincer-Zarnowitz — foi atingido. As dollar bars dominaram em todas as quatro dimensões de avaliação. O coeficiente de determinação MZ foi de $R^2 = 0,655$ para as dollar bars, contra $R^2 = 0,493$ para as time bars, diferença de 16,2 pontos percentuais.

O quinto objetivo — comparar o desempenho preditivo tendo o estimador TSRV como referência — foi igualmente atingido. O TSRV serviu como benchmark de volatilidade diária; ambos os modelos GARCH apresentaram subestimação sistemática leve, evidenciada pelos interceptos negativos da regressão MZ ($\hat{\alpha}_{DB} = -1,08 \times 10^{-4}$ e $\hat{\alpha}_{TB} = -2,54 \times 10^{-4}$). Esse padrão é característico de modelos GARCH paramétricos estimados com inovações gaussianas quando confrontados com estimadores não-paramétricos de alta frequência, que

capturam componentes de variação intrajornada não presentes no modelo.

5.2 RESPOSTA À PERGUNTA CENTRAL

A pergunta de pesquisa que motivou este trabalho indaga: *em que medida a escolha do método de amostragem afeta a qualidade das estimativas de volatilidade obtidas por modelos ARMA-GARCH?*

Os resultados indicam que a escolha afeta de forma relevante tanto as propriedades estatísticas das séries de retornos quanto o desempenho preditivo fora da amostra dos modelos. No plano distribucional, a diferença é dramática: curtose 25 vezes menor e assimetria quase nula nas dollar bars, frente a caudas extremamente pesadas e assimetria negativa pronunciada nas time bars. No plano preditivo, a diferença é economicamente significativa: redução de 34% no MSE, de 24% no MAE e de 16 pontos percentuais no R^2 da regressão de Mincer-Zarnowitz, além de ICs bootstrap para o QLIKE que não se sobrepõem a 95% de confiança.

A significância estatística formal, avaliada pelo teste de Diebold-Mariano, não atinge o limiar convencional de 5% (estatística $DM = -1,9578$, $p\text{-valor} = 0,0503$), mas o argumento baseado exclusivamente nessa fronteira seria epistemicamente incompleto. O poder do teste é limitado pelo número de dias de sobreposição entre os conjuntos de previsão (147 dias), e o $p\text{-valor}$ de 0,0503 constitui evidência fraca contra a hipótese nula, não evidência a seu favor. A combinação de sinal inequívoco na estatística DM, dominância em todas as métricas pontuais e não sobreposição dos ICs bootstrap para o QLIKE configura evidência consistente — ainda que não conclusiva ao nível convencional — em favor das dollar bars.

É importante destacar que este resultado não é apenas confirmatório de ??). O autor argumenta, no plano teórico e com ilustrações empíricas, que barras de informação produzem séries com propriedades distribucional superiores, mas não testa diretamente modelos de previsão de volatilidade nem utiliza métricas específicas para comparação de previsões. O presente trabalho estende essa análise para o contexto de modelos GARCH — a classe de modelos mais amplamente empregada para volatilidade condicional — e quantifica a diferença de desempenho com funções de perda robustas da classe de ??), fornecendo evidência empírica nova sobre a utilidade prática das dollar bars em um contexto de previsão.

5.3 CONTRIBUIÇÕES DO TRABALHO

Este trabalho apresenta três contribuições concretas à literatura.

A primeira é de natureza metodológica. A utilização do *Combinatorial Purged Cross-Validation* para seleção de hiperparâmetros em modelos GARCH — procedimento que elimina vazamento de informação temporal por meio de purga e embargo, e que explora todas as $\binom{N}{K}$ combinações de folds em vez de um único caminho de validação — representa um avanço em relação ao walk-forward simples usualmente empregado na literatura brasileira de modelos de volatilidade. A implementação computacional, que realizou 72.576 ajustes MLE em aproximadamente 17 minutos por meio de um backend em Rust, é documentada de forma reproduzível e pode ser reutilizada para outros ativos e especificações.

A segunda contribuição é empírica. O presente trabalho oferece a primeira comparação sistemática, ao menos no contexto da literatura acadêmica brasileira, entre dollar bars e time bars como insumo para modelos GARCH aplicados a criptomoedas, com avaliação out-of-sample via estimador TSRV e métricas robustas de Patton (2011). A extensão da análise de ??) para o problema específico de previsão de volatilidade condicional preenche uma lacuna identificada na revisão de literatura.

A terceira contribuição é técnica. O *pipeline* computacional desenvolvido em Python com backend em Rust demonstra que é possível realizar seleção de hiperparâmetros por CPCV para modelos GARCH em escala prática — 36.288 ajustes MLE por série em menos de nove minutos por pipeline —, tornando o procedimento viável sem infraestrutura computacional especializada.

5.4 LIMITAÇÕES

As principais limitações do trabalho foram discutidas em detalhe na seção 4.4. Resumidamente: os resultados referem-se a um único ativo de criptomoeda (BTC/USDT na Binance), sobre um período de dois anos (2024–2025), com limiar $\bar{D}$ fixo calibrado para equiparar o número médio de barras por dia entre as duas séries, e com inovações gaussianas em ambos os modelos GARCH. A generalização das conclusões para outros ativos, períodos ou especificações requer estudos adicionais.

5.5 AGENDA DE PESQUISA FUTURA

Os resultados obtidos abrem um conjunto de direções para investigação futura.

A mais imediata é a replicação do estudo em outras classes de ativos. Ações brasileiras listadas na B3, o câmbio BRL/USD e commodities negociadas em mercados regulados apresentam microestruturas distintas das criptomoedas — com leilões de abertura e fechamento, circuit breakers e menor fragmentação de liquidez — o que permitiria

investigar se a superioridade das dollar bars é específica ao mercado de criptomoedas ou se é uma propriedade mais geral do método de amostragem.

Uma segunda extensão natural é a re-estimação dos modelos com distribuições de cauda pesada para as inovações, particularmente a t-Student e a Distribuição de Erro Generalizado (GED). Dado o excesso de curtose documentado, especialmente nas time bars, a adoção de inovações não-gaussianas poderia melhorar o ajuste e, potencialmente, alterar a magnitude das diferenças de desempenho entre os tipos de barra.

??) propõe outros tipos de barras de informação além das dollar bars, entre elas as volume bars e as tick bars, bem como as imbalance bars, que condicionam o tamanho da barra ao desequilíbrio entre ordens de compra e venda. Uma comparação mais abrangente entre esses tipos de barra forneceria um panorama mais completo sobre qual estrutura de amostragem é mais informativa para modelos de volatilidade.

No plano dos modelos de volatilidade, caberia investigar se a superioridade das dollar bars se mantém com especificações que capturam assimetria e efeitos de alavancagem, como o EGARCH (??) e o GJR-GARCH (??), ou com modelos de volatilidade estocástica, que tratam a variância latente como uma variável de estado não-observada. Esses modelos podem ser particularmente relevantes para as dollar bars, cuja dinâmica de volatilidade demandou um componente GARCH(1, 2) em vez do canônico GARCH(1, 1).

Por fim, o presente trabalho avaliou previsões *one-step-ahead* da variância diária. Previsões multi-step — de 5, 10 e 22 dias úteis, horizontes relevantes para gestão de risco e cálculo de capital regulatório — podem exibir padrões distintos de desempenho relativo entre os tipos de barra, em função da estrutura de persistência da volatilidade capturada por cada modelo. Essa extensão representaria uma contribuição diretamente aplicável a contextos práticos de gestão de risco quantitativo.

REFERÊNCIAS BIBLIOGRÁFICAS

- AKAIKE, H. A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, v. 19, n. 6, p. 716–723, 1974. [14](#)
- ANDERSEN, T. G. et al. Modeling and forecasting realized volatility. *Econometrica*, v. 71, n. 2, p. 579–625, 2003. [15](#), [16](#), [24](#), [40](#)
- BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, v. 31, n. 3, p. 307–327, 1986. [8](#), [13](#), [14](#)
- BOLLERSLEV, T.; CHOU, R. Y.; KRONER, K. F. ARCH modeling in finance: A review of the theory and empirical evidence. In: *Journal of Econometrics*. [S.l.: s.n.], 1992. v. 52, n. 1–2, p. 5–59. [14](#)
- BOX, G. E. P.; JENKINS, G. M. *Time Series Analysis: Forecasting and Control*. San Francisco: Holden-Day, 1970. [13](#)
- DIEBOLD, F. X. Comparing predictive accuracy, twenty years later: A personal perspective on the use and abuse of diebold–mariano tests. *Journal of Business & Economic Statistics*, v. 33, n. 1, p. 1–24, 2015. [39](#), [41](#)
- DIEBOLD, F. X.; MARIANO, R. S. Comparing predictive accuracy. *Journal of Business & Economic Statistics*, v. 13, n. 3, p. 253–263, 1995. [20](#), [40](#)
- EFRON, B.; TIBSHIRANI, R. J. *An Introduction to the Bootstrap*. Boca Raton, FL: CRC Press, 1993. [21](#)
- ENGLE, R. F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, v. 50, n. 4, p. 987–1007, 1982. [8](#), [14](#), [15](#)
- MINCER, J. A.; ZARNOWITZ, V. The evaluation of economic forecasts. In: *Economic Forecasts and Expectations: Analysis of Forecasting Behavior and Performance*. [S.l.]: National Bureau of Economic Research, 1969. p. 3–46. [20](#), [40](#)
- PATTON, A. J. Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, v. 160, n. 1, p. 246–256, 2011. [19](#), [20](#), [36](#), [39](#), [41](#), [45](#)
- PRADO, M. López de. *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons, 2018. [8](#), [9](#), [11](#), [12](#), [18](#), [27](#), [37](#), [38](#)
- SCHWARZ, G. Estimating the dimension of a model. *The Annals of Statistics*, v. 6, n. 2, p. 461–464, 1978. [14](#)
- TSAY, R. S. *Analysis of Financial Time Series*. 3. ed. Hoboken, NJ: John Wiley & Sons, 2010. [8](#), [13](#), [14](#), [15](#), [27](#)
- ZHANG, L.; MYKLAND, P. A.; AÏT-SAHALIA, Y. A tale of two time scales: Determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, v. 100, n. 472, p. 1394–1411, 2005. [16](#), [17](#), [24](#), [25](#)

Apêndices